Podstawy Pythona dla Data Science

Wykład 3: Pandas, SciPy i scikit-learn w analizie danych inżynierskich

Lu Pa

April 13, 2026

Czym jest Pandas?

- Wysokopoziomowa biblioteka do pracy z danymi tabelarycznymi.
- Zbudowana na NumPy.
- Zapewnia:
  - struktury DataFrame i Series
  - szybkie filtrowanie i grupowanie
  - obsługe braków danych
  - łaczenie i scalanie danych
- Standard w czyszczeniu i raportowaniu danych.

Wczytywanie danych

```
import pandas as pd

df = pd.read_csv("../datasets/vehicle_speeds_trackA.csv")
df.info()
df.head()
```

Czyszczenie danych

- Usuwanie wartości niemożliwych:
  - ujemna predkość
  - skoki RPM
- Obsługa braków danych:
  - usuwanie wierszy
  - interpolacja
- Konwersja jednostek (km/h $\rightarrow$ m/s).

Filtrowanie za pomoca masek logicznych

```
high_speed = df[df["speed_kmh"] > 80]
braking = df[df["accel_mps2"] < -1.5]
cruise = df[(df["speed_kmh"] > 40) & (df["accel_mps2"].abs() < 0.2)]
```

Grupowanie i agregacja

```
df["minute"] = (df["time_s"] // 60).astype(int)

summary = df.groupby("minute").agg({
    "speed_kmh": ["mean", "max"],
    "fuel_rate_gps": "mean",
    "engine_rpm": "mean"
})
```

SciPy w sygnałach inżynierskich

- SciPy rozszerza NumPy o:
  - przetwarzanie sygnałów
  - optymalizacje
  - interpolacje
  - statystyke
- Dziś: filtrowanie niskoprzepustowe.

Filtr dolnoprzepustowy SciPy

```
from scipy.signal import butter, filtfilt

b, a = butter(3, 0.05)
v_filtered = filtfilt(b, a, df["speed_kmh"])
```

scikit-learn w modelowaniu

- Biblioteka ML do:
  - regresji
  - klasyfikacji
  - klasteryzacji
- Dziś: regresja liniowa na danych telemetrycznych.

Prognozowanie zużycia paliwa na podstawie predkości

```
from sklearn.linear_model import LinearRegression
import numpy as np

X = df[["speed_kmh"]].values
y = df["fuel_rate_gps"].values

model = LinearRegression()
model.fit(X, y)

print(model.coef_, model.intercept_)
```

Wizualizacja dopasowania regresji

```
plt.scatter(df["speed_kmh"], df["fuel_rate_gps"], s=5)
plt.plot(df["speed_kmh"], model.predict(X), color="red")
plt.xlabel("Predkość [km/h]")
plt.ylabel("Zuzycie paliwa [g/s]")
plt.grid(True)
plt.show()
```

Zadania inżynierskie

- Wyczyść dane Track A i Track B.
- Zidentyfikuj fazy: przyspieszanie, hamowanie, jazda ustalona.
- Zastosuj filtr dolnoprzepustowy do predkości.
- Zbuduj model regresji przewidujacy zużycie paliwa.
- Porównaj styl jazdy na Track A i Track B.